

گزارش:

کالبد شکافی چالش های فنی و منطقی:
چالش ها:

برای scatter plot بعد از وارد کردن نام محور ها برای آنکه نقطه ها را بر اساس یک ستون رنگ بندی کند پارامتر hue را نیز از کاربر دریافت میکنیم موقع امتحان کردن حالت های مختلف متوجه شدم اگر ان را artists وارد کنیم خطا میدهد بعد متوجه شدم بعضی از اسم ها داخل خودشان \$ دارند برای رفع این مشکل در اسم هایی که "\$" داشتند با "" جایگزین کردم

برای پاک سازی اگر کاربر ستون های غیر عددی وارد میکرد خطا میداد برای همین بعد از انتخاب ستون اول با یکی از متود های پانداس بررسی میکرد که ستون عددی هست یا نه اگر عددی بود در مورد روش پاکسازی چند تا انتخاب میاورد و بر اساس انتخاب کاربر پاکسازی میکرد و اگر عددی نبود برای پاکسازی مقادیر گمشده انها را با Unknown جایگزین کردم

Z-Score: به معنای این است که عدد ما چند برابر انحراف معیار از میانگین فاصله دارد که در اینجا اگر بیشتر از 3 برابر باشد حذف میشود


IQR: به معنای این است که تمام داده هایی که بیشتر از حد پایین و بالای نمودار باشند حذف خواهند شد حد پایین برابر با $Q1 - 1.5 * IQR$ و بالا $Q3 + 1.5 * IQR$ است هماهنگ سازی KNN با شی گرایی: این کلاس از کلاس BaseImputer ارث بری میکند و به دلیل ساختار چند ریختی متد impute() را دارد

تجربیات یادگیری:

ساختار شی گرا باعث میشود کد منظم و قابل توسعه باشد در بخش هایی که از مفهوم وراثت استفاده شده باعث میشود تمام کلاس ها از یکی ارث بری کنند و در صورت نیاز میتوان روش های جدید را بازنویسی کرد


در کلاس Song از property و setter استفاده شده تا مقادیر اعتبارسنجی بشوند اصل DRY: بجای اینکه یک عمل تکراری را در بخش های مختلف تکرار کنم با استفاده از توابع و کلاس ها پیاده سازی شده و فقط هنگام نیاز فراخوانی میشوند این کار باعث میشود کد خوانتر و قابل توسعه تر شود

تحلیل و داستان سرایی داده ها:




این نمودار میزان همبستگی بین ویژگی های عددی را نشان میدهد هر قدر که میزان همبستگی به 1 نزدیک تر باشد رابطه مستقیم تری دارند اعداد منفی به معنای رابطه معکوس میباشد


بر اساس نمودار energy و loudness بیشترین رابطه و energy و acousticness کمترین رابطه را دارا می باشند و با توجه به نمودار میزان محبوبیت اهنگ تقریباً مستقل از ویژگی های صوتی میباشد و میتواند تحت تاثیر عوامل غیر عددی مانند خواننده باشد




این نمودار پراکندگی رابطه بین دو ویژگی **energy** و **speechiness** را برای ژانر های مختلف نشان میدهد با توجه به نمودار در اغلب ژانر ها میزان موسیقی از میزان گفتار بیشتر میباشد در سمت راست نمودار نقاطی با **speechiness** نزدیک به 1 دیده میشود که برای ژانر هایی مانند کمدی میباشد و همچنین با توجه به نمودار ویژگی انرژی تمام بازه بین 0 تا 1 را شامل میشود



before outlier handling



after IQR cleaning



after Z-Score cleaning

این نمودار ها توزیع ویژگی **tempo** قبل و بعد از پاک سازی نشان میدهند با توجه به نمودار اولیه داده هایی که خارج از محدوده طبیعی قرار دارند به عنوان داده پرت شناخته شده و با دایره نمایش داده میشوند در پاکسازی با روش **IQR** داده هایی که از خارج از محدوده نمودار هستند حذف شده و در روش **Z_Score** داده هایی که بیش از 3 انحراف

معیار از میانگین فاصله دارند حذف میشوند با توجه به دو نمودار بعد از پاکسازی دیده از میشود که عملکرد روش IQR از روش دیگر مناسب تر بوده و همچنین متوجه میشویم حذف کردن داده های پرت تاثیر چندانی روی چارک های داده ندارد